Pranje novca u digitalnom dobu: Uloga forenzičnog računovodstva

Od kriptovaluta do detekcije anomalija pomoću AI

Antonio Labinjan

Fakultet Informatike u Puli

March 28, 2026

Uvod: Evolucija financijskog kriminala

- **Digitalizacija:** Veća učinkovitost vs. sofisticirani oblici kriminala.
- **Evolucija metoda:** Prijelaz s fiktivnih poduzeća na algoritme i kriptovalute.
- **Glavni izazov:** Brzina transakcija i anonimnost otežavaju rad regulatorima.
- **Forenzično računovodstvo:** Disciplina koja objedinjuje računovodstvo, reviziju i istražiteljska znanja.

Teorijski okvir i zakonska regulativa

Definicija

Proces prikrivanja nezakonitog podrijetla novca kako bi se prikazao kao legalan prihod.

- **FATF (Financial Action Task Force):** Globalni standardi (40 preporuka).
- **VASP:** Poseban fokus na mjenjačnice i skrbnike kriptovaluta.
- **Zakon o SPNFT (RH):** Obveza provođenja **KYC** (Know Your Customer) analize.

FATF: Globalni "policajac" za pranje novca

- **Uloga:** Međuvladino tijelo koje postavlja standarde za borbu protiv pranja novca (AML) i financiranja terorizma (CFT).
- **40 preporuka:** Temeljni dokument koji države moraju implementirati u svoje zakone.
- **Sive i crne liste:** Države koje se ne pridržavaju standarda (poput Sjeverne Koreje ili Irana) suočavaju se s teškim financijskim sankcijama.
- **Tehnološki imperativ:** FATF zahtijeva da institucije koriste sustave temeljene na **procjeni rizika** (Risk-Based Approach), što izravno opravdava korištenje algoritama poput Benforda.

VASP: Virtual Asset Service Providers

- **Definicija:** Bilo koji subjekt koji omogućuje razmjenu, prijenos ili čuvanje virtualne imovine (kripto mjenjačnice, skrbnički novčanici).
  Travel Rule (Pravilo putovanja):
  - Najveći izazov za kripto industriju.
  - Obveza prikupljanja i prijenosa podataka o pošiljatelju i primatelju za svaku transakciju iznad određenog praga (npr. 1.000 EUR).
- **Cilj:** Ukinuti potpunu anonimnost transakcija i izjednačiti kripto sektor s tradicionalnim bankarstvom.

Zakon o SPNFT (RH) i operativna kontrola

- **Zakon o sprječavanju pranja novca i financiranja terorizma:** Glavni pravni akt u Hrvatskoj usklađen s EU direktivama.
- **KYC (Know Your Customer) proces:**
  - Identifikacija i provjera identiteta stranke.
  - Utvrđivanje stvarnog vlasnika poduzeća (*UBO - Ultimate Beneficial Owner*).
  - Stalno praćenje poslovnog odnosa.
- **Obveznici:** Banke, računovođe, odvjetnici, ali i **digitalne platforme**.
- **Uloga forenzičara:** Provjera jesu li KYC procesi samo "mrtvo slovo na papiru" ili se transakcije doista nadziru.

Tri faze pranja novca u digitalnom kontekstu

Faza	**Opis**	**Digitalni primjer**
Polaganje	Ulazak novca u sustav	Kripto-bankomati bez ID-a
Prikrivanje	Niz kompleksnih transakcija	Korištenje "mixera" i Monera
Integracija	Povrat vlasniku kao "čist"	Isplata "dobiti" od investicija

Tradicionalna revizija vs. Forenzična istraga

Tradicionalna revizija

- Cilj: Fer i istiniti izvještaji.
- Metoda: Uzorkovanje.
- Pretpostavka točnosti.

Forenzična istraga

- Cilj: Otkrivanje prijevare i počinitelja.
- Metoda: Analiza cijele baze podataka.
- Istražiteljski skepticizam.

Kriptovalute i metode prikrivanja

- **Bitcoin:** Pseudoniman (transakcije su javno zabilježene na blockchainu).
- **Monero (XMR):** Napredna kriptografija (prstenasti potpisi) za potpunu anonimnost.
- **Mixers/Tumblers:** Servisi koji atomiziraju transakcije i ponovno ih spajaju u nasumičnim intervalima.
- **Cilj:** Kidanje linearnog traga novca.

Fiktivna e-trgovina i Cyber-smurfing

- **Shell e-trgovina:** Lažne web trgovine prodaju nepostojeće digitalne proizvode (e-knjige, licence).
- **Cyber-smurfing:**
  - Digitalno usitnjavanje transakcija.
  - Ostajanje ispod praga izvještavanja (npr. 10.000 EUR).
  - Automatizirano korištenje botova i mreže "mula".

Identifikacija raniih indikatora (Red Flags)

- **Bihevioralni:** Nagli porast volumena, rapidno kretanje sredstava, transakcije prema poreznim oazama.
- **Tehnološki:**
  - Česta promjena IP adresa (VPN/Proxy).
  - Pristup isključivo preko Tor preglednika.
  - Korištenje neregistriranih digitalnih novčanika (*unhosted wallets*).

Slučaj Silk Road: Arhitektura "nevidljivog" tržišta

- **Dark Web i Tor:** Tržište je operiralo na .onion domeni, skrivajući IP adrese poslužitelja i korisnika.
- **Ross Ulbricht ("Dread Pirate Roberts"):** Osnivač koji je vjerovao u potpunu anonimnost slobodnog tržišta.
- **Bitcoin kao jedino sredstvo plaćanja:** Izbor Bitcoina (2011.-2013.) bio je temeljen na pretpostavci da transakcije nisu povezive s identitetom.
- **Uloga "mixera":** Silk Road je imao ugrađen interni servis za miješanje bitcoina kako bi spriječio praćenje isplata s platforme.

Metoda detekcije: Analiza klastera i "Change Address"

- **Analiza klastera (Clustering):** Grupiranje tisuća različitih adresa za koje se može dokazati da ih kontrolira isti entitet.
- **Heuristika zajedničkog ulaza:** Ako transakcija troši sredstva s više adresa odjednom, forenzičar zaključuje da pripadaju istom novčaniku.
- **Praćenje kusura (*Change Address*):** Bitcoin transakcije šalju višak natrag pošiljatelju. Analitičari su pratili taj "tok" koji se uvijek vraćao u iste čvorove.

Ključni uvid

Blockchain nije anoniman, već **transparentan**. Svaki se "novčić" može pratiti od nastanka do trenutne adrese.

Digitalni otisci: Kako je pao Dread Pirate Roberts?

- **Povezivanje digitalnog i fizičkog:** Istražitelji su povezali Ulbrichtov rani upit na Stack Overflowu (pod pravim imenom) s kodom korištenim za Silk Road.
- **Zapljena laptopa:** Ključni trenutak u knjižnici u San Franciscu – laptop je zaplijenjen dok je Ulbricht bio prijavljen kao administrator ("mastermind").
- **Nepobitan dokaz (144.000 BTC):** Forenzičari su pronašli izravne transakcije s poslužitelja Silk Roada u Ulbrichtov privatni novčanik.
- **Legacy:** Ovaj slučaj je potaknuo razvoj modernih alata poput *Chainalysis* i *Elliptic* koje danas koriste porezne uprave i policija.

Matematički modeli: Što je zapravo Benfordov zakon?

- **Fenomen prve znamenke:** U prirodnim skupovima podataka, znamenka 1 se kao prva javlja u $\approx 30\%$ slučajeva, dok se znamenka 9 javlja u manje od 5%.
- **Logaritamska distribucija:** Vjerojatnost pojave znamenke d definirana je formulom:

$$P(d) = \log_{10}(1 + \frac{1}{d})$$

- **Primjenjivost:** Financijske transakcije, iznosi na računima, cijene dionica, broj stanovnika gradova.
- **Forenzički uvid:** Perači novca i falsifikatori obično biraju brojeve "iz glave" (poput 5 ili 7), što drastično narušava ovu prirodnu krivulju.

Analiza anomalije: Zašto je znamenka 5 sumnjiva?

Znamenka	Očekivano	Stvarno
1	30.1%	15.0%
2	17.6%	16.2%
5	**7.9%**	**22.0%**
9	4.6%	3.8%

Table: Usporedba frekvencija

Interpretacija rezultata:

- **Under-reporting (1):** Perač izbjegava niske iznose jer želi brže "oprati" veće sume.
- **Clustering (5):** Fiksni iznosi botova (npr. 50, 500, 5000 EUR) stvaraju neprirodan vrhunac.
- **Deep Dive:** Forenzičar sada fokusira resurse isključivo na transakcije koje počinju s 5.

Praktična primjena: Automatizirani sustav detekcije

- **Integracija:** Sustav analizira transakcije u realnom vremenu direktno iz baze podataka ili blockchain čvora.
- **Tehnološki stack:**
  - **Python** (Numpy, Matplotlib) za matematičku obradu i vizualizaciju.
  - **Streamlit** za interaktivno sučelje (Dashboard) namijenjen istražiteljima.
- **Glavni cilj:** Smanjenje "buke" (Noise) u podacima – automatizirano izdvajanje sumnjivih obrazaca koje ljudsko oko ne može primijetiti u milijunima unosa.

Interaktivna simulacija i Source Code

Live Demo Dashboard

- Simulacija Cyber-smurfinga.
- Prikaz odstupanja u realnom vremenu.
- Automatsko generiranje alarma (Status: ALARM/OK).

Pristup izvornom kodu:

GitHub: Online dashboard

- *Napomena: Kod je optimiziran za Streamlit framework i omogućuje istražiteljima testiranje različitih scenarija manipulacije prvom znamenkom.*

AI kao prijetnja: Nova era financijskog kriminala

- **Sintetički identiteti i Deepfake:**
  - Zaobilaženje video-identifikacije (KYC) pomoću generiranih lica i glasova.
  - Izrada uvjerljivih lažnih dokumenata u milisekundama.
- **Inteligentni "Cyber-smurfing":**
  - Botovi više ne koriste fiksne iznose (koje Benford lako otkrije).
  - AI simulira ljudsku "nasumičnost" i uobičajene obrasce potrošnje kako bi ostao ispod radara.
- **Automatsko izbjegavanje pravila:** Algoritmi koji uče pragove detekcije banaka i prilagođavaju rute kretanja novca u hodu.

AI kao rješenje: Napredna forenzička analitika

- **Graph Analytics (Analiza mreža):**
  - Vizualizacija milijuna transakcija kao "paukovu mrežu".
  - Otkrivanje skrivenih korelacija između naizgled nepovezanih digitalnih novčanika.
- **NLP (Natural Language Processing):**
  - Skeniranje "Open Source Intelligence" (OSINT) izvora.
  - Automatska identifikacija politički izloženih osoba (PEP) i negativnih vijesti u realnom vremenu.

Prediktivna obrana

AI ne čeka da se prevara dogodi; on predviđa sumnjivo ponašanje na temelju anomalija u mikrosekundama.

Budućnost forenzike: Augmentirana inteligencija

- **Problem "Crne kutije" (Black Box):** AI može detektirati anomaliju, ali forenzični računovođa mora **objasniti** zašto je to dokaz na sudu.
- **Explainable AI (XAI):** Fokus na sustave koji daju razloge za "crvenu zastavicu".
- **Etička prosudba:** AI nema moralni kompas – konačna odluka o istrazi i pravna kvalifikacija ostaju u domeni čovjeka.

"Tehnologija je multiplikator snage, ali istražiteljski instinkt je kormilo."

Zaključak

- Digitalno pranje novca odvija se u milisekundama, ali ostavlja **trajne otiske**.
- Forenzično računovodstvo je superiorno zbog spoja financijske analize i IT znanja.
- Tehnologija nije rješenje sama po sebi; ključna je **kontinuirana edukacija** i istražiteljski instinkt.